

Laporan Praktikum Minggu Ke-4 Kontrol Cerdas

Minggu ke-4

Nama : Bara Hafidz Adz Dzikro

NIM : 224308053

Kelas : TKA 7C

Akun GitHub (Tautan) : <https://github.com/barahafidz224308053tka-maker>

1. Judul Percobaan

Reinforcement Learning for Autonomous Control

2. Tujuan Percobaan

Tujuan dari percobaan pada praktikum kali ini sebagai berikut:

1. Memahami konsep dasar Reinforcement Learning (RL) dalam sistem kendali.
2. Mengimplemtasikan agen RL menggunakan algoritma Deep Q-Network (DQN).
3. Menggunakan OpenAI Gym sebagai simulasi lingkungan untuk pelatihan RL.
4. Melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom.
5. Menggunaka GitHub untuk version control dan dokumentasi praktikum.

3. Landasan Teori

Machine learning adalah cabang kecerdasan buatan (AI) yang memungkinkan sistem komputer belajar dari data dan meningkatkan kinerjanya tanpa diprogram secara eksplisit. Dengan menggunakan algoritma statistik dan matematika, machine learning dapat mengenali pola, membuat prediksi, dan mengambil keputusan secara otomatis. Teknologi ini digunakan dalam berbagai bidang, seperti deteksi penipuan, pengenalan wajah, rekomendasi produk, dan analisis data medis. Machine learning terbagi menjadi tiga jenis utama: supervised learning, unsupervised learning, dan reinforcement learning, yang masing-masing memiliki metode dan penerapan

yang berbeda. (Apa itu Machine Learning: Definisi, Konsep Dasar, dan Implementasinya, 2025)

Reinforcement learning (RL) adalah pendekatan pembelajaran di mana agen kecerdasan buatan (AI) berinteraksi dengan lingkungannya melalui metode coba-coba dan belajar strategi perilaku optimal berdasarkan sinyal reward yang diterima dari interaksi sebelumnya. Proses pembelajaran agen RL ini meniru pendekatan pembelajaran manusia/hewan. Salah satu aspek paling bermanfaat dari RL adalah kemampuannya beradaptasi dengan bidang sains dan teknik lainnya. RL telah muncul sebagai teknik efisien untuk menyelesaikan tugas pengambilan keputusan berurutan yang kompleks dalam beberapa tahun terakhir. Ia menawarkan peluang besar untuk membuka frontier baru dalam teknologi di mana model sistem tidak tersedia atau terlalu sulit dan/atau mahal untuk dibangun. RL modern merupakan kombinasi dari tiga bidang penelitian: psikologi pembelajaran manusia, pemecahan masalah kontrol optimal menggunakan Program Dinamis (DP), dan pembelajaran perbedaan temporal (TD) (Shakya et al., 2023).

Deep Q-Learning adalah metode yang menggunakan pembelajaran mendalam untuk membantu mesin membuat keputusan dalam situasi yang rumit. Metode ini sangat berguna dalam lingkungan dengan jumlah kemungkinan situasi (state) yang sangat besar, seperti dalam gim video atau robotika. Q-Learning efektif untuk masalah kecil, tetapi kesulitan untuk masalah kompleks seperti gambar atau berbagai kemungkinan situasi. Dalam implementasinya terdapat beberapa Tantangan yang Ditangani oleh Deep Q-Learning, antara lain: 1.) Ruang Keadaan Berdimensi Tinggi: Q-Learning tradisional menggunakan tabel untuk menyimpan nilai, tetapi hal ini menjadi mustahil ketika terdapat terlalu banyak situasi. Jaringan saraf tiruan dapat memahami dan menangani banyak situasi berbeda sekaligus, sehingga lebih baik untuk permasalahan kompleks. 2.) Data Masukan Berkelanjutan: Permasalahan dunia nyata seringkali memiliki data berkelanjutan seperti gambar video. Jaringan saraf tiruan sangat baik dalam menangani informasi semacam ini. 3.) Skalabilitas: Pembelajaran mendalam membantu Q-Learning

tumbuh dan menangani tugas yang lebih besar dan lebih sulit yang sebelumnya tidak dapat diselesaikan oleh Q-Learning biasa. (Deep Q-Learning in Reinforcement Learning, 2025)

4. Analisis dan Diskusi

❖ Analisa:

1. Bagaimana performa agen dalam mengontrol environment CartPole?

Cartpole juga disebut sebagai Bandul Terbalik adalah bandul dengan pusat gravitasi di atas titik porosnya. Bandul ini tidak stabil, tetapi dapat dikendalikan dengan memindahkan titik porosnya ke bawah pusat massa. Tujuannya adalah menjaga cartpole tetap seimbang dengan menerapkan gaya yang sesuai pada titik porosnya. Untuk melihat Performa dari CartPole-v1 kita dapat melihatnya dari pelatihan, arsitektur jaringan saraf, dan jumlah episode pelatihan yang dijalankan. Pada percobaan praktikum ini, kita melakukan pelatihan pada agen menggunakan salah satu algoritma dari Reinforcement Learning yaitu algoritma DNQ (Deep Q-Network) dengan menggunakan DNQ pada saat pelatihan agen mampu menyelesaikan CartPole dengan stabil dengan jumlah episode sebesar 1000, lalu didapatkan nilai rata-rata reward sebesar 200, yang artinya tiang bisa dijaga seimbang sampai batas waktu episode berakhir.

2. Bagaimana perubahan parameter (misal: gamma, epsilon, learning rate) mempengaruhi kinerja agen?

Dalam proses pembelajaran agen pada lingkungan seperti CartPole, sejumlah parameter inti—yakni gamma, epsilon, dan learning rate—sangat menentukan efektivitas serta keberhasilan agen dalam menjaga keseimbangan tiang. Nilai gamma berperan sebagai faktor diskon yang mengatur seberapa jauh agen menimbang keuntungan jangka panjang, pada parameter epsilon bekerja sebagai pengatur keseimbangan antara eksplorasi terhadap tindakan baru dan eksploitasi dari strategi yang sudah dipelajari. Pada parameter learning rate bertugas menentukan seberapa besar langkah perubahan bobot jaringan saraf saat pembaruan dilakukan. Tingkat learning rate yang terlalu tinggi dapat menimbulkan ketidakstabilan, karena pembaruan bobot menjadi terlalu drastis dan mudah kehilangan arah. Sebaliknya, jika nilainya terlalu

rendah, proses belajar berlangsung sangat lambat sehingga agen membutuhkan waktu lama untuk mencapai hasil yang memadai.

3. Apa tantangan yang muncul selama pelatihan agen RL?

Terdapat beberapa tantangan yang muncul pada saat pelatihan agen RL seperti membutuhkan sumber daya yang besar untuk mencapai performa yang baik maka dari itu dapat mempengaruhi waktu komputasi data tersebut, selain itu penentuan parameter agen seperti parameter gamma, epsilon, dan learning rate, harus sesuai sehingga agen RL dapat beradaptasi pada lingkungan dengan karakteristik yang dinamis dan kompleks. Proses ini tidak hanya meningkatkan performa agen RL, selain itu dapat memastikan bahwa agen dapat generalisasi dengan baik pada situasi yang belum pernah dilihat sebelumnya.

❖ Diskusi

1. Apa perbedaan utama antara Reinforcement Learning dan metode supervised learning dalam sistem kendali?

Reinforcement Learning adalah metode pembelajaran di mana sistem (disebut agen) belajar melalui interaksi dengan lingkungannya. Agen akan mengambil tindakan, menerima umpan balik berupa reward (hadiah) atau punishment (hukuman), lalu memperbaiki strategi untuk mencapai tujuan tertentu. Sedangkan Supervised Learning adalah metode pembelajaran mesin di mana model dilatih menggunakan data yang sudah diberi label. Artinya, setiap data input memiliki output atau jawaban yang benar. Model kemudian belajar dari data tersebut untuk memprediksi hasil pada data baru. Maka dari itu RL lebih cocok diterapkan pada sistem kendali yang dinamis dan tidak sepenuhnya dapat diprediksi, misalnya kendali robot atau manajemen energi, karena agen mampu beradaptasi dengan kondisi yang berubah-ubah. Sedangkan supervised learning biasanya lebih stabil tetapi kurang fleksibel jika diterapkan pada lingkungan yang kompleks dan tidak terstruktur.

2. Bagaimana strategi eksplorasi (exploration) dan eksploitasi (exploitation) dapat dioptimalkan pada agen RL?

Strategi eksplorasi merupakan proses di mana agen mencoba tindakan yang belum pernah dicoba sebelumnya untuk menemukan reward yang lebih baik. Mengoptimalkan proses eksplorasi dalam Reinforcement Learning (RL) sangat penting agar agen dapat menemukan tindakan terbaik dan tidak terjebak dalam pilihan yang kurang efektif. Sedangkan strategi eksploitasi merupakan proses di mana agen menggunakan pengetahuan yang telah dipelajari untuk memilih tindakan yang diharapkan memberikan reward tertinggi. Setelah agen memiliki pemahaman yang baik tentang environment, eksploitasi menjadi lebih penting untuk memaksimalkan reward.

3. Potensi aplikasi lain dari RL dalam sistem kendali nyata apa saja yang dapat diimplementasikan?

Reinforcement Learning adalah paradigma pembelajaran mesin yang memungkinkan agen untuk belajar secara mandiri melalui interaksi dengan lingkungan. Kemampuan Reinforcement Learning untuk mengoptimalkan keputusan dan mempelajari kebijakan melalui berbagai proses percobaan telah membuatnya menjadi metode yang menarik dan efektif dalam berbagai bidang. salah satu bidang yang dapat mengimplementasikan RL adalah pada bidang robotika dan control otomatis, dengan menggunakan RL memungkinkan robot untuk belajar secara mandiri melalui trial & error, mengoptimalkan gerakan dan tindakan mereka untuk mencapai tujuan yang diinginkan. Selain itu, RL juga digunakan dalam kontrol otomatis untuk mengoptimalkan sistem yang kompleks, seperti sistem kendali lalu lintas, pengaturan suhu bangunan, atau pengendalian mesin industri

5. Assignment

Pada percobaan praktikum ini kita melakukan percobaan mengenai implementasi dari algoritma Deep Q-Network (DQN) yang digunakan untuk melatih environment agen CartPole-v0 tujuan dari agen ini adalah menjaga tiang tetap seimbang di atas kereta, dengan reward positif setiap langkah ketika

tiang tidak jatuh. selain itu kita juga melakukan pelatihan pada environment MountainCar-v0. Tujuan dari agen ini yaitu mencapai puncak bukit dengan menggunakan aksi yang optimal, tetapi reward yang didapat sangat terbatas. langkah pertama yang dilakukan adalah dengan mengimpor beberapa library yang diperlukan, seperti gymnasium untuk environment reinforcement learning, numpy untuk operasi numerik, random untuk pemilihan acak, dan deque dari collections untuk menyimpan pengalaman. Selain itu, tensorflow.keras digunakan untuk membangun model jaringan saraf. langkah selanjutnya adalah mendefinisikan agen DQN dengan menggunakan nama kelas DQNAgent, Agen diinisialisasi dengan ukuran keadaan dan ukuran aksi. Beberapa parameter penting juga digunakan, seperti parameter gamma, yang berperan sebagai faktor diskon yang mengatur seberapa jauh agen menimbang keuntungan jangka panjang, Parameter epsilon bekerja sebagai pengatur keseimbangan antara eksplorasi terhadap tindakan baru dan eksploitasi dari strategi yang sudah dipelajari, Adapun learning rate bertugas menentukan seberapa besar langkah perubahan bobot jaringan saraf saat pembaruan dilakukan.





Pada eksperimen pertama CartPole-V1, agen harus menjaga tiang tetap tegak di atas gerobak/kotak. Lingkungan ini cukup sederhana, sehingga agen dapat belajar dengan cepat. Setiap kali agen berhasil menjaga tiang tetap tegak, ia mendapatkan reward positif, Agen dapat dengan stabil mencapai tujuannya karena lingkungan ini lebih mudah diprediksi, pada code yang saya buat untuk melakukan percobaan pelatihan pada cartpole-v0, terdapat beberapa parameter yang saya masukkan, seperti : $\gamma = 0.95$, $\epsilon = 1.0$, $\text{learning_rate} = 0.001$ dan $\text{batch_size} = 32$.

pada MountainCar-v0, agen harus menggerakkan mobil ke puncak bukit, tetapi mobil tidak memiliki cukup tenaga untuk langsung mencapai tujuan. Agen harus belajar membangun momentum dengan bergerak maju dan mundur. Reward di MountainCar-v0 lebih susah karena mobil tidak berhasil mencapai puncak, yang membuat pembelajaran menjadi lebih sulit. Model yang digunakan memerlukan arsitektur yang lebih kompleks atau teknik tambahan untuk meningkatkan stabilitas. Proses pelatihan untuk MountainCar

memerlukan lebih banyak episode. sebelum agen dapat mencapai kinerja yang baik. Dalam code yang saya buat untuk melakukan training pada MountainCar-v0, terdapat beberapa parameter yang saya buat, antara lain: $\gamma = 0.99$, $\epsilon = 1.0$, $\text{learning_rate} = 0.001$ dan $\text{memory} = \text{deque}(\text{maxlen}=2000)$.

6. Data dan Output Hasil Pengamatan

No.	Variabel	Hasil Pengamatan	
		Chart pole v1	Mountain Car v0
1.	Waktu Pelatihan	Chartpole lebih cepat dalam mencapai performa optimal saat episode diatas 100 dan waktu pelatihan yang lebih singkat dari MountainCar	Mountain car membutuhkan waktu lama pada saat pelatihan dan membutuhkan episode diatas 1000 untuk performa yang optimal
2.	Kinerja Agen	Kinerja agen CartPole mampu menghasilkan skor yang lebih tinggi	Masih menghadapi kesulitan dalam mencapai kondisi optimal terutama untuk mencapai puncak
3.	Kondisi Berhasil	Kondisi episode berakhir ketika tiang jatuh atau batas waktu tercapai	Kondisi berhasil jika mobil berhasil mencapai puncak bukit (bendera)

4.	Hasil Episode Awal		
5.	Hasil Episode Akhir		

7. Kesimpulan

Berdasarkan percobaan pada saat praktikum, diskusi dan analisis yang telah dilakukan, maka didapatkan kesimpulan yaitu:

1. CartPole-v1 merupakan salah satu simulasi klasik dalam bidang reinforcement learning yang bertujuan untuk menyeimbangkan sebuah tiang vertikal yang dipasang pada kereta bergerak. Agen bertugas mengendalikan pergerakan kereta agar tiang tidak jatuh, lebih banyak total reward yang diperoleh maka dalam mempertahankan posisi tiang tetap tegak akan lebih lama.
2. MountainCar-v0 lebih sulit dipelajari karena menghadirkan masalah kontrol klasik di mana sebuah mobil diposisikan di lembah di antara dua gunung. sehingga Agen harus belajar mengemudi maju mundur untuk membangun momentum guna mencapai tujuan
3. Pada saat melakukan pelatihan terdapat beberapa factor yang dapat mempengaruhi hasil pelatihan dan performa agen, yaitu : Jumlah layer dan neuron, - Jumlah episode dan iterasi dan batch size, parameter gamma, parameter epsilon dan parameter learning rate.

8. Saran

Dalam pengembangan algoritma reinforcement learning untuk lingkungan simulasi seperti MountainCar dan CartPole, pendekatan yang berbasis Markov Decision Process (MDP) sangat relevan dan strategis. Markov Decision Process (MDP) adalah kerangka kerja untuk menggambarkan masalah pengambilan keputusan berurutan. Dalam pembelajaran mesin, masalah seperti klasifikasi dan regresi adalah tugas satu kali. Artinya, model klasifikasi/regresi diberi masukan dan mengembalikan keluaran. Kemudian, masukan berikutnya yang diberikan sepenuhnya independen dari yang pertama. Dalam masalah pengambilan keputusan berurutan, kita perlu membuat serangkaian keputusan dari waktu ke waktu, di mana setiap keputusan memengaruhi kemungkinan masa depan. Dalam MDP, terdapat empat komponen utama yang saling berkaitan. Pertama, State (S) merepresentasikan keadaan sistem saat ini, misalnya posisi dan kecepatan mobil dalam MountainCar atau sudut dan posisi tiang pada CartPole. Kedua, Action (A) adalah pilihan aksi yang dapat diambil oleh agen, seperti mendorong ke kiri, kanan, atau tetap diam. Ketiga, Transition Probability (P) menggambarkan probabilitas perpindahan dari satu keadaan ke keadaan lain sebagai akibat dari aksi yang dilakukan. Terakhir, Reward Function (R) memberikan umpan balik kepada agen berdasarkan aksi yang diambil, yang digunakan untuk mengarahkan proses pembelajaran menuju pencapaian tujuan tertentu. Dengan menjadikan MDP sebagai fondasi pengembangan, sistem yang dibangun akan lebih terstruktur,

9. Daftar Pustaka

Shakya, A. K., Pillai, G., & Chakrabarty, S. (2023). Reinforcement learning algorithms: A brief survey. *Expert Systems with Applications*, 231(May), 120495. <https://doi.org/10.1016/j.eswa.2023.120495>

Apa itu Machine Learning: Definisi, Konsep Dasar, dan Implementasinya. (2025, Maret 24). Retrieved from DigitalSkola: <https://digitalskola.com/blog/data-science/machine-learning-2>

Deep Q-Learning in Reinforcement Learning. (2025, Juli 12). Retrieved from
GeeksforGeeks: <https://www.geeksforgeeks.org/deep-learning/deep-q-learning/>